



ΥΠΟΛΟΓΙΣΤΙΚΗ ΝΟΗΜΟΣΥΝΗ 2025-2026

- ΔΗΜΗΤΡΙΟΣ ΝΤΑΟΥΛΤΖΗΣ 5311
- ΠΑΥΛΟΣ ΜΠΑΣΟΥΚΕΑΣ 5296

Τμήμα 2 – Κατασκευή Συνόλου Δεδομένων ΣΔΟ (Πρόβλημα Ομαδοποίησης 9 Ομάδων)

1. Περιγραφή του Προβλήματος

Στο δεύτερο μέρος της εργασίας ζητείται η δημιουργία ενός συνόλου δεδομένων κατάλληλου για προβλήματα **ομαδοποίησης (clustering)**.

Το σύνολο δεδομένων αποτελείται συνολικά από **1200 σημεία** στο επίπεδο (x_1, x_2) , όπου κάθε ομάδα σημείων δημιουργείται με ομοιόμορφη κατανομή μέσα σε συγκεκριμένα ορθογώνια υποσύνολα του τετραγώνου $[0,2] \times [0,2]$.

Το σύνολο αποτελείται από:

- **9 ομάδες σημείων (clusters)**
- **150 σημεία θορύβου (noise)** ομοιόμορφα κατανεμημένα σε όλο το τετράγωνο

Οι ομάδες έχουν διαφορετικό πλήθος σημείων:
5 ομάδες των 150 σημείων και 4 ομάδες των 75 σημείων.

2. Γεωμετρικός Ορισμός των Ομάδων

Τα σημεία παράγονται ομοιόμορφα στα παρακάτω ορθογώνια διαστήματα:

Cluster	Περιοχή	Πλήθος
1	$[0.75, 1.25] \times [0.75, 1.25]$	150
2	$[0, 0.5] \times [0, 0.5]$	150
3	$[0, 0.5] \times [1.5, 2]$	150
4	$[1.5, 2] \times [0, 0.5]$	150
5	$[1.5, 2] \times [1.5, 2]$	150
6	$[0.6, 0.8] \times [0, 0.4]$	75
7	$[0.6, 0.8] \times [1.6, 2]$	75
8	$[1.2, 1.4] \times [0, 0.4]$	75
9	$[1.2, 1.4] \times [1.6, 2]$	75
10 (θόρυβος)	$[0, 2] \times [0, 2]$	150

Οι εννέα πρώτες περιοχές σχηματίζουν διακριτές ομάδες (clusters), ενώ η δέκατη περιέχει δεδομένα που λειτουργούν ως θόρυβος.

3. Μέθοδος Υλοποίησης

Η υλοποίηση έγινε σε **Java** μέσω του αρχείου DatasetO.java.

Για κάθε ορθογώνιο διάστημα $[a, b] \times [c, d]$ παράγονται τυχαία σημεία με τη σχέση:

$$x_1 = a + U \cdot (b - a), x_2 = c + U \cdot (d - c),$$

όπου U είναι ομοιόμορφα κατανεμημένος τυχαίος αριθμός στο $[0,1]$.

Έτσι εξασφαλίζεται ομοιόμορφη τυχαιότητα μέσα στο κάθε υποσύνολο.

Για αναπαραγωγιμότητα χρησιμοποιήθηκε **σταθερό seed (1234)**:

```
Random rnd = new Random(1234);
```

Κάθε σημείο αποθηκεύτηκε ως αντικείμενο της κλάσης `DataPoint` με πεδία x_1 , x_2 και `label`, όπου το `label` δείχνει σε ποια ομάδα ανήκει (1–10).

Στο τέλος, όλα τα σημεία γράφτηκαν σε αρχείο `dataset_O.csv` για χρήση στις ασκήσεις.

4. Σύνολο Δεδομένων – Ποσότητες ανά Ομάδα

Το πρόγραμμα δημιουργεί ακριβώς:


- 9 ομάδες συνολικού πλήθους 1050 σημείων
- 150 σημεία θορύβου
- **Σύνολο: 1200 σημεία**

5. Παρατηρήσεις – Συμπεράσματα

- Οι εννέα ομάδες σχηματίζουν καθαρά και διακριτά clusters, ομοιόμορφα κατανεμημένα στις καθορισμένες περιοχές.

- Τα σημεία θορύβου δρουν ως "τυχαία διάσπαρτα" δεδομένα στο χώρο και κάνουν το πρόβλημα πιο ρεαλιστικό για clustering.
- Η χρήση σταθερού seed επιτρέπει αναπαραγωγή των ίδιων δεδομένων σε μελλοντικά πειράματα.

Οπτική απεικόνιση του dataset ΣΔΟ με 9 ομάδες και θόρυβο, σύμφωνα με την εκφώνηση.



Άσκηση 2 – Ομαδοποίηση με k-means στο σύνολο ΣΔΟ

Σκοπός της άσκησης είναι η υλοποίηση προγράμματος ομαδοποίησης (ΠΟ) βασισμένου στον αλγόριθμο k-means, η εφαρμογή του στο σύνολο δεδομένων ΣΔΟ και η μελέτη του πώς επηρεάζεται το σφάλμα ομαδοποίησης από τον αριθμό των ομάδων M.

1. Περιγραφή αλγορίθμου

Υλοποιήθηκε ο αλγόριθμος k-means με τα ακόλουθα βήματα:

1. Φόρτωμα δεδομένων

Τα 1200 δισδιάστατα παραδείγματα (x_1, x_2) του συνόλου ΣΔΟ φορτώνονται από το αρχείο dataset_O.csv.

Κάθε παράδειγμα αποθηκεύεται ως αντικείμενο DataPoint με πεδία (x_1, x_2, label) .

2. Αρχικοποίηση κέντρων

Για δεδομένο αριθμό ομάδων M, τα αρχικά κέντρα $\mu_1, \dots, \mu_M$ επιλέγονται τυχαία από τα ίδια τα παραδείγματα, εξασφαλίζοντας ότι δεν επιλέγεται το ίδιο παράδειγμα δύο φορές ως κέντρο.

3. Ανάθεση σημείων σε ομάδες (assignment step)

Για κάθε παράδειγμα x_i υπολογίζεται η Ευκλείδεια απόσταση από κάθε κέντρο μ_k και το παράδειγμα ανατίθεται στην ομάδα με το πλησιέστερο κέντρο:

$$k(i) = \arg \min_k \|x_i - \mu_k\|^2.$$

4. Ενημέρωση κέντρων (update step)

Για κάθε ομάδα k, το νέο κέντρο υπολογίζεται ως ο μέσος όρος των σημείων που ανήκουν στην ομάδα:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

Σε περίπτωση που κάποια ομάδα προκύψει κενή (δεν έχει σημεία), το αντίστοιχο κέντρο επανατοποθετείται σε τυχαίο σημείο από το σύνολο δεδομένων.

5. Κριτήριο τερματισμού

Ο αλγόριθμος επαναλαμβάνει τα βήματα ανάθεσης–ενημέρωσης μέχρι τα κέντρα να σταθεροποιηθούν. Ως κριτήριο σύγκλισης χρησιμοποιήθηκε το μέγιστο διάστημα μετατόπισης των κέντρων:

$$\max_k \|\mu_k^{(v+1)} - \mu_k^{(v)}\| < \varepsilon,$$

με $\varepsilon = 10^{-6}$.

Επίσης χρησιμοποιήθηκε μέγιστος αριθμός επαναλήψεων (MAX_ITEERS = 300) για αποφυγή πιθανής μη σύγκλισης.

6. Σφάλμα ομαδοποίησης

Μετά τη σύγκλιση, το σφάλμα ομαδοποίησης υπολογίζεται ως:

$$J = \sum_{i=1}^N \|x_i - \mu_{k(i)}\|^2.$$

2. Πειραματική διαδικασία

Για κάθε τιμή του αριθμού ομάδων $M = 3, 5, 7, 9, 11, 13$ εκτελέστηκαν:

- **50 ανεξάρτητα runs** του k-means, με διαφορετική τυχαία αρχικοποίηση των κέντρων,
- για κάθε run τυπώθηκε το σφάλμα ομαδοποίησης J ,
- επιλέχθηκε η λύση με **ελάχιστο J** και αποθηκεύτηκαν τα αντίστοιχα κέντρα σε αρχείο CSV (π.χ. kmeans_best_centers_M3.csv κ.λπ.).

Για το “καλύτερο” run κάθε τιμής M δημιουργήθηκαν σε Octave διαγράμματα όπου:

- τα παραδείγματα του συνόλου ΣΔΟ απεικονίζονται με σύμβολο ‘+’,
- τα κέντρα των ομάδων με σύμβολο ‘*’.

Έτσι είναι δυνατή η οπτική επιβεβαίωση της δομής των ομάδων και της θέσης των κέντρων.

3. Διάγραμμα σφάλματος J ως συνάρτηση του M

Συγκεντρώθηκαν οι ελάχιστες τιμές σφάλματος $J_{\min}(M)$ για κάθε M και κατασκευάστηκε το διάγραμμα $J_{\min}$ σε συνάρτηση με τον αριθμό των ομάδων M .

Παρατηρήθηκε ότι:

- Το σφάλμα ομαδοποίησης **μειώνεται μονοτονικά** καθώς αυξάνεται ο αριθμός των ομάδων M , γεγονός αναμενόμενο, καθώς με περισσότερα κέντρα το μοντέλο μπορεί να προσαρμοστεί καλύτερα στα δεδομένα.
- Για μικρές τιμές του M (π.χ. $M=3,5$) το σφάλμα είναι σχετικά μεγάλο, ενώ για M κοντά στο 9 το σφάλμα παρουσιάζει μια πιο έντονη μείωση και στη συνέχεια η βελτίωση γίνεται πιο ήπια (φαινόμενο “elbow”).

4. Εκτίμηση του πραγματικού αριθμού ομάδων


Στο σύνολο ΣΔΟ ο πραγματικός αριθμός ομάδων είναι $M_{\text{πραγμ}} = 9$ (όπως δίνεται στην εκφώνηση). Από το διάγραμμα σφάλματος $J(M)$ παρατηρείται ότι γύρω από την τιμή $M \approx 9$ εμφανίζεται σημείο καμπής, όπου η μείωση του σφάλματος από M σε $M+2$ γίνεται σημαντικά μικρότερη σε σχέση με τις προηγούμενες τιμές.

Συμπερασματικά, **το σφάλμα ομαδοποίησης μπορεί να χρησιμοποιηθεί ως ένδειξη για την εκτίμηση του πραγματικού αριθμού ομάδων**, όμως:


- δεν δίνει πάντα μοναδική και ξεκάθαρη απάντηση
- απαιτείται οπτικός έλεγχος του σχήματος
- ίσως σε άλλα προβλήματα χρειαστούν και πρόσθετα κριτήρια.

Στο συγκεκριμένο πρόβλημα ΣΔΟ, η συμπεριφορά του $J(M)$ είναι συμβατή με την ύπαρξη **9 ομάδων**.


$M=3$




$M=5$




M=7




M=9



M=11



M=13



Διάγραμμα που να δείχνει πώς μεταβάλλεται το σφάλμα ομαδοποίησης με τον αριθμό των ομάδων:

